

UNIVERSIDADE PRESBITERIANA MACKENZIE
CURSO SUPERIOR DE TECNOLOGIA EM BANCO DE DADOS

LEANDRO HENRIQUE PEREIRA
MURILO FREITAS RODRIGUES
THALLES RODRIGUES

DESENVOLVIMENTO E AVALIAÇÃO DE UM MODELO DE MACHINE
LEARNING PARA RECOMENDAÇÃO DE JOGOS NA STEAM
ETAPA 2
REFERENCIAL TEÓRICO E PROVA DE CONCEITO

SÃO PAULO
2026

**LEANDRO HENRIQUE PEREIRA
MURILO FREITAS RODRIGUES
THALLES RODRIGUES**

**DESENVOLVIMENTO E AVALIAÇÃO DE UM MODELO DE MACHINE
LEARNING PARA RECOMENDAÇÃO DE JOGOS NA STEAM
ETAPA 2
REFERENCIAL TEÓRICO E PROVA DE CONCEITO**

Trabalho acadêmico apresentado à disciplina Projeto Aplicado III, do curso de Banco de Dados, da Universidade Presbiteriana Mackenzie, como parte das atividades avaliativas referentes à segunda etapa.

Professor: Gustavo Scalabrini Sampaio.

**SÃO PAULO
2026**

SUMÁRIO

1 INTRODUÇÃO.....	4
1.1 Contexto do trabalho.....	4
1.2 Motivação.....	4
1.3 Justificativa e problema de pesquisa.....	5
1.4 Objetivos.....	5
1.5 Objetivo extensionista e relação com os ODS.....	6
1.6 Dataset e delimitação dos dados.....	6
1.7 Visão geral do pipeline.....	8
2 REFERENCIAL TEÓRICO.....	9
2.1 Recomendação e natureza dos sinais de preferência.....	9
2.2 Filtragem colaborativa baseada em itens.....	9
2.3 Aprendizado de ordenação e abordagens sequenciais.....	10
2.4 Evidências no domínio Steam.....	11
2.5 Avaliação e reprodutibilidade.....	11
2.6 Popularidade e limites das métricas offline.....	12
2.7 Síntese e posicionamento do projeto.....	12
REFERÊNCIAS.....	14
APÊNDICE A PROVA DE CONCEITO DA ETAPA 2.....	15
A.1 Bibliotecas e preparação.....	15
A.2 Análise exploratória.....	16
A.3 Treinamento e protocolo de avaliação.....	17
A.4 Resultados preliminares.....	20
A.5 Demonstração e próximos passos.....	21

1 INTRODUÇÃO

1.1 Contexto do trabalho

A crescente expansão do mercado de jogos digitais tem proporcionado aos usuários acesso a um catálogo cada vez mais amplo de títulos. Plataformas como a Steam disponibilizam milhares de jogos com diferentes gêneros, preços e características, sendo a escolha de um novo título uma tarefa potencialmente complexa. Nesse contexto, sistemas de recomendação assumem um papel relevante ao auxiliar os usuários na descoberta de jogos compatíveis com seus interesses e comportamentos.

A coleção pública Steam Video Game and Bundle Data reúne diferentes arquivos de avaliações, interações e metadados. A primeira etapa citou os números gerais divulgados no catálogo: 7.793.069 avaliações, 2.567.538 usuários, 15.474 itens e 615 bundles (McAuley, s.d.). Esses totais caracterizam a coleção anunciada, mas não devem ser confundidos com o arquivo efetivamente processado nesta etapa.

O produto proposto é um recomendador personalizado de jogos individuais. Dado um histórico de jogos avaliados positivamente, o sistema produz uma lista ordenada de dez títulos ainda não presentes nesse histórico. A prova de conceito utiliza a versão 1 pública da coleção, com dados de avaliações da comunidade australiana, e compara a filtragem colaborativa baseada em itens com uma referência não personalizada de popularidade. O objetivo nesta fase é verificar a viabilidade do procedimento e suas limitações, antes da implementação definitiva.

1.2 Motivação

A motivação técnica consiste em transformar registros esparsos de interação em sugestões que possam apoiar a descoberta de jogos. O problema é concreto: o mesmo catálogo contém usuários com históricos muito curtos e jogos com níveis muito diferentes de exposição. Uma recomendação por popularidade pode oferecer títulos amplamente conhecidos, mas não considera diretamente as combinações de interesses de cada usuário.

No contexto da formação em Banco de Dados, o projeto permite integrar aquisição de dados públicos, controle de qualidade, representação matricial, aprendizado de padrões e avaliação reproduzível. Essa articulação justifica a escolha

de um experimento auditável, no qual cada decisão de preparação e cada resultado possam ser relacionados aos registros de origem. A viabilidade computacional e a possibilidade de explicar associações entre itens orientam a escolha inicial de um modelo de vizinhança.

1.3 Justificativa e problema de pesquisa

A utilização de um sistema de recomendação nesse contexto é justificada tanto pela necessidade de lidar com a grande quantidade de opções disponíveis quanto pela possibilidade de utilizar o comportamento coletivo dos usuários para identificar relações entre jogos. Por meio da análise das interações entre usuários e itens, bem como de características dos jogos e dos bundles, é possível investigar diferentes abordagens de recomendação, como métodos baseados no comportamento dos usuários, nas características dos itens ou na combinação dessas informações.

A aplicação concentra-se, nesta etapa, nas avaliações positivas disponíveis. Informações de preços e bundles permanecem como possibilidades de evolução, sem serem apresentadas como recursos já implementados. Esse recorte permite estabelecer uma referência técnica verificável e evita atribuir ao protótipo capacidades que ainda não foram avaliadas.

O problema de pesquisa é: em que medida a filtragem colaborativa baseada em similaridade entre jogos recupera avaliações positivas omitidas, em comparação com a recomendação por popularidade, e qual é o efeito dessa escolha sobre a cobertura do catálogo? A hipótese de trabalho é que a personalização pode alterar o equilíbrio entre acerto e exposição de itens. Sua superioridade não é presumida: deve ser examinada pelas métricas calculadas em dados separados do treinamento.

1.4 Objetivos

1.4.1 Objetivo geral

Desenvolver e avaliar um sistema de recomendação personalizada de jogos da Steam utilizando o histórico de interações dos usuários.

1.4.2 Objetivos específicos

- Caracterizar a base selecionada, distinguindo os totais da coleção e o arquivo utilizado na prova de conceito.

- Identificar valores ausentes, duplicidades, concentração de interações e limitações dos históricos disponíveis.
- Preparar uma matriz esparsa usuário-jogo, com regras explícitas de seleção e separação dos dados.
- Ajustar um modelo colaborativo baseado em itens e compará-lo com uma referência por popularidade.
- Avaliar a recuperação de itens por Precision@10, Recall@10, NDCG@10 e MRR@10, juntamente com cobertura e concentração das recomendações.
- Documentar o código, os parâmetros, as fontes e os resultados para permitir a reprodução da análise.
- Propor uma ação extensionista de educação sobre recomendação e consumo digital informado, distinguindo atividades planejadas de resultados efetivamente obtidos.

1.5 Objetivo extensionista e relação com os ODS

O projeto mantém a vinculação proposta aos ODS 9 e 12, mas separa essa finalidade do objetivo técnico. A relação com o ODS 9 está na formação e difusão de capacidades tecnológicas; a relação potencial com o ODS 12 está na reflexão sobre escolhas digitais informadas (Nações Unidas Brasil, s.d.a; s.d.b). Recomendar jogos não comprova, por si só, sustentabilidade ambiental nem redução de consumo.

Propõe-se, para uma etapa posterior, uma oficina aberta a estudantes e à comunidade interessada, acompanhada de um guia breve sobre como recomendações são produzidas, como a popularidade interfere na exposição dos jogos e quais informações o usuário deve conferir antes de adquirir um título. O público parceiro, a data e as responsabilidades deverão ser acordados pela equipe. A comprovação poderá incluir material disponibilizado, registro de participação voluntária e um questionário curto sobre a compreensão das limitações do sistema. Nenhuma oficina, parceria, economia financeira ou melhoria de bem-estar é apresentada como já realizada.

1.6 Dataset e delimitação dos dados

1.6.1 Origem e versões

A fonte é o repositório acadêmico da Universidade da Califórnia em San Diego, mantido por Julian McAuley. O arquivo principal desta prova de conceito é

australian_user_reviews.json.gz, identificado no catálogo como Version 1: Review Data. Seu uso mantém o domínio Steam da proposta, mas constitui uma delimitação explícita em relação aos totais gerais inicialmente informados. Não se trata de uma amostra aleatória de 59 mil registros extraída, nesta execução, das 7,8 milhões de avaliações.

Tabela 1 Comparação entre a coleção anunciada e os arquivos utilizados

Aspecto	Coleção anunciada	Arquivo de reviews v1
Avaliações	7.793.069	59.305 registros expandidos
Usuários	2.567.538	25.458 com ao menos uma review
Jogos	15.474	3.682 identificadores
Bundles	615	Não utilizados no treinamento

Fonte: catálogo UCSD para os totais gerais; contagem executada em Python para a versão 1. As populações e os arquivos não são equivalentes.

O artigo associado à comunidade australiana descreve coleta a partir da comunidade GameAus e analisa recomendações de bundles (Pathak; Gupta; McAuley, 2017). Seus números se referem ao recorte experimental daquele estudo, não ao número de linhas de reviews contado aqui. As datas textuais do arquivo processado incluem anos de 2010 a 2015; 10.119 registros brutos não explicitam o ano. Não se atribuiu artificialmente um ano a essas observações. Por essa razão, a avaliação inicial é retrospectiva e aleatória, sem alegação de previsão temporal.

1.6.2 Informações disponíveis e uso nesta etapa

Tabela 2 Dicionário operacional dos dados

Campo	Significado	Tratamento
user_id	Identificador de usuário	Pseudonimização por SHA-256; chave user no CSV
item_id	Identificador de jogo	Preservado como texto; chave item
recommend	Recomendação explícita booleana	True define interação positiva; False é contabilizado na auditoria
posted	Data em texto da avaliação	Preservada; não usada para divisão cronológica
title	Nome histórico do jogo	Obtido dos metadados v2 apenas para exibição

Os metadados `steam_games.json.gz` são de outra versão da coleção e não entram no treinamento ou nas métricas. A junção por identificador é utilizada somente para tornar a demonstração legível, com fallback para o próprio ID quando não há título. Os nomes são históricos; não representam necessariamente a denominação atual na loja. Não foram utilizados textos de reviews, URLs de perfis, atributos pessoais ou preços correntes.

1.6.3 Bundles e limites do escopo

A primeira etapa descreveu `bundle_id`, `bundle_name`, `bundle_price`, `bundle_final_price`, `bundle_discount`, `bundle_url` e a lista `items`. Essa descrição permanece como contexto de possível expansão. Um bundle reúne itens comercializados em conjunto; essa associação não equivale automaticamente a similaridade de gosto. O exemplo Two Tribes Complete Pack, formado por Toki Tori, Toki Tori 2+, RUSH e EDGE, ilustra a estrutura informada no catálogo (McAuley, s.d.). Nenhum desses preços ou descontos foi tratado como atual.

A prova de conceito recomenda jogos individuais e não otimiza compras, preços ou composição de pacotes. Avaliações negativas são preservadas na base auditada, mas não participam da matriz positiva. Assim, o protótipo não garante bloquear um jogo anteriormente rejeitado. Essa limitação deve ser resolvida antes de uma aplicação destinada a usuários reais. Da mesma forma, ausência de avaliação não significa rejeição e uma review não comprova compra.

1.7 Visão geral do pipeline

O pipeline compreende obtenção dos arquivos oficiais, extração dos campos necessários, auditoria e remoção de pares duplicados, seleção de avaliações positivas, separação em treino, validação e teste, ajuste das similaridades entre jogos e avaliação das listas geradas. O vocabulário do modelo e as estatísticas usadas na recomendação são calculados exclusivamente no treino. A validação escolhe os hiperparâmetros; o teste é reservado à comparação final desta prova de conceito.

A seção 2 apresenta o referencial teórico; o Apêndice A registra a prova de conceito. As seções finais serão desenvolvidas nas próximas etapas. Repositório da equipe: <https://github.com/ThallesRodri/ProjetoAplicado3>.

2 REFERENCIAL TEÓRICO

Esta revisão narrativa reúne fundamentos de recomendação e trabalhos diretamente relacionados ao domínio Steam, à avaliação e ao viés de popularidade. As fontes foram escolhidas por sua pertinência à pergunta de pesquisa e verificadas em páginas dos autores, repositórios acadêmicos ou editoras. Incluem estudos clássicos e publicações de 2024 e 2025. Não se reivindica uma revisão sistemática exaustiva.

2.1 Recomendação e natureza dos sinais de preferência

A recomendação personalizada utiliza relações entre usuários e itens para ordenar alternativas compatíveis com interesses observados. Na filtragem colaborativa, essas relações são inferidas dos padrões de interação da comunidade, em vez de depender exclusivamente de atributos descritivos dos produtos. Métodos baseados em conteúdo utilizam características dos itens; soluções híbridas combinam fontes de informação (Google, s.d.).

No presente problema, o atributo recommend é feedback explícito binário: o usuário declara recomendar ou não recomendar um jogo. Ele difere de sinais implícitos como cliques, compras e tempo de uso. A transformação adotada retém apenas as recomendações positivas para construir uma matriz de presença. Portanto, o problema computacional é de recuperação de positivos conhecidos que foram ocultados, e não de classificação direta de toda a população de avaliações positivas e negativas.

Essa distinção evita confundir não observação com rejeição. Uma célula sem interação positiva pode representar desconhecimento, falta de exposição, ausência de avaliação ou rejeição não incorporada pelo modelo. O ranking é uma estimativa baseada em evidências parciais, sem interpretação de probabilidade calibrada de satisfação. O fato de um jogo não ser recuperado em um teste de um único item também não demonstra que os demais jogos recomendados seriam indesejados.

2.2 Filtragem colaborativa baseada em itens

Sarwar et al. (2001) investigam algoritmos que estimam relações entre itens a partir de padrões de avaliações. Seu estudo discute similaridade por cosseno e agregação de relações entre itens para produzir recomendações. Essa família de

métodos é pertinente quando se deseja uma primeira solução interpretável e passível de comparação com referências simples.

Na adaptação deste projeto, cada jogo é representado por um vetor binário de usuários que o avaliaram positivamente no conjunto de treino. A similaridade cresce quando dois jogos compartilham usuários, levando em conta a frequência individual de cada um. O conjunto de vizinhos de um jogo é obtido a partir dos dados; por isso, ajustar o modelo significa estimar e armazenar sua estrutura de similaridades, mesmo sem utilizar uma rede neural ou um processo por épocas.

A associação calculada é comportamental: não demonstra semelhança de gênero, qualidade, preço ou narrativa. Poucas coocorrências podem produzir relações instáveis, especialmente para itens raros. Por esse motivo, a implementação acrescenta um fator de redução para relações sustentadas por poucos usuários. A fórmula e a escolha dos parâmetros pertencem ao procedimento experimental documentado no Apêndice A, sem atribuir essa implementação particular integralmente ao estudo de 2001.

2.3 Aprendizado de ordenação e abordagens sequenciais

Rendle et al. (2009) formulam o Bayesian Personalized Ranking, que aprende preferências relativas entre itens observados e não observados por meio de um critério de ordenação. O trabalho sustenta a distinção entre otimizar listas personalizadas e prever notas numéricas. A fatoração treinada com BPR é uma alternativa pertinente para etapas posteriores, especialmente quando se deseja aprender representações latentes de usuários e jogos.

Kang e McAuley (2018) propõem o SASRec, uma abordagem sequencial baseada em autoatenção. A técnica explora a ordem das interações para modelar o próximo item, em um problema diferente da recuperação aleatória empregada aqui. Sua discussão mostra que a escolha do modelo depende também da qualidade dos históricos e da definição temporal da tarefa.

Não se implementaram BPR ou SASRec nesta prova de conceito. A comparação teórica delimita alternativas sem apresentar resultados inexistentes. Como há datas sem ano explícito e históricos de reviews curtos, avançar para avaliação sequencial exige resolver primeiro a qualidade temporal, escolher um protocolo que impeça acesso a informações futuras e verificar se as sequências de avaliações representam adequadamente a tarefa desejada.

2.4 Evidências no domínio Steam

Pathak, Gupta e McAuley (2017) estudam a recomendação e a geração personalizada de bundles na Steam. O trabalho trata a compatibilidade entre conjuntos de jogos e utiliza informação de interações para construir modelos de preferência. Sua relevância para este projeto é demonstrar que o domínio comporta diferentes tarefas: sugerir um jogo, ordenar pacotes existentes ou gerar novos pacotes.

A continuidade proposta mantém a base e o domínio da primeira etapa, mas resolve inicialmente a tarefa mais delimitada de recomendar títulos individuais. A formação comercial de um pacote não será usada como evidência suficiente de afinidade pessoal. Comparar resultados numéricos diretamente com o artigo seria inadequado, pois o alvo, o recorte dos dados, a preparação e as métricas não são os mesmos. A contribuição desta etapa é estabelecer uma referência local reproduzível para o grupo, e não reivindicar superar a literatura.

2.5 Avaliação e reprodutibilidade

Ferrari Dacrema, Benigni e Ferro (2025), em estudo disponibilizado como preprint, analisam a consistência de artefatos e resultados de trabalhos de recomendação baseados em passagem de mensagens. Entre os problemas discutidos estão divisões inadequadas dos dados, vazamento entre treinamento e teste e comparações frágeis com modelos de referência. A pertinência do estudo está no rigor do protocolo, e não na adoção obrigatória de modelos complexos.

No projeto, essa preocupação se traduz em partições disjuntas, parâmetros escolhidos na validação, manutenção de uma referência por popularidade e divulgação dos resultados mesmo quando a personalização não vence. O conjunto de candidatos, os critérios de elegibilidade dos usuários e a quantidade de itens relevantes por usuário são especificados porque alteram a interpretação das métricas. O código, os hashes e as divisões materializadas documentam o experimento.

Precision@10 expressa a fração de posições ocupadas por itens considerados relevantes no teste. Recall@10 mede a fração dos relevantes recuperados. NDCG@10 e MRR@10 valorizam a posição do item recuperado. Nesta implementação há exatamente um positivo de teste por usuário; por isso, Recall@10

coincide com a taxa de acerto e Precision@10 corresponde a essa taxa dividida por dez. Essa consequência do protocolo deve acompanhar qualquer leitura dos números.

2.6 Popularidade e limites das métricas offline

Klimashevskaja et al. (2024) revisam o viés de popularidade, suas formas de mensuração e estratégias de mitigação. Os autores discutem que concentrar recomendações em itens populares pode limitar a descoberta, mas também destacam a necessidade de considerar efeitos concretos para usuários e fornecedores. Assim, uma distribuição menos concentrada não comprova automaticamente maior utilidade ou justiça.

Daniil et al. (2024) investigam a reprodução de resultados sobre popularidade em diferentes domínios. O estudo mostra que dados, algoritmos, agrupamento dos usuários e estratégia de avaliação contribuem para diferenças nas conclusões. Essa evidência recomenda cautela ao transferir um ganho obtido em determinado protocolo para outra população ou contexto de uso.

Por essa razão, a prova de conceito complementa as métricas de acerto com cobertura do catálogo e participação dos jogos do décimo mais popular do treino nas listas. Essas medidas descrevem exposição agregada, mas não medem diversidade semântica, satisfação, economia financeira ou benefício extensionista. A avaliação offline também depende dos itens que foram observados e avaliados; ela não oferece conhecimento completo sobre todas as preferências possíveis de cada pessoa.

2.7 Síntese e posicionamento do projeto

A literatura fundamenta três escolhas: delimitar o alvo da recomendação, iniciar por um modelo colaborativo interpretável e avaliar qualidade de ordenação juntamente com exposição do catálogo. O estudo aplicado é exploratório e reproduzível, voltado à comparação entre ItemKNN e popularidade em dados públicos da Steam. A proposta não introduz um algoritmo inédito; investiga a adequação de técnicas existentes ao recorte selecionado.

Quadro 1 Relação entre as referências e as decisões do projeto

Referência	Contribuição ao projeto
Sarwar et al. (2001)	Fundamenta relações item-item e modelos de vizinhança.
Rendle et al. (2009)	Situa o aprendizado de ordenação como alternativa futura.
Pathak, Gupta e McAuley (2017)	Contextualiza a Steam e distingue jogos de bundles.
Kang e McAuley (2018)	Delimita a alternativa sequencial e sua exigência temporal.
Klimashevskaja et al. (2024)	Orienta a discussão de popularidade e exposição.
Daniil et al. (2024)	Sustenta cautela na comparação de protocolos.
Ferrari Dacrema, Benigni e Ferro (2025)	Orienta consistência entre código, partições e resultados.

Fonte: elaboração própria a partir das referências citadas. O quadro sintetiza decisões do projeto e não constitui comparação experimental entre os artigos.

O avanço para as próximas etapas será condicionado pelas evidências do protótipo. Se houver perda de acerto acompanhada de ganho de cobertura, a decisão deverá explicitar esse compromisso, em vez de declarar melhoria geral. Novos modelos, bases maiores e avaliações com pessoas poderão ser considerados, sem reutilizar o teste atual para orientar repetidamente a escolha de parâmetros.

REFERÊNCIAS

- DANIIL, Savvina; CUPER, Mirjam; LIEM, Cynthia C. S.; VAN OSSENBRUGGEN, Jacco; HOLLINK, Laura. Reproducing popularity bias in recommendation: the effect of evaluation strategies. *ACM Transactions on Recommender Systems*, v. 2, n. 1, art. 5, p. 1-39, 2024. DOI: 10.1145/3637066. Disponível em: <https://ir.cwi.nl/pub/33989>. Acesso em: 2 out. 2026.
- FERRARI DACREMA, Maurizio; BENIGNI, Michael; FERRO, Nicola. Reproducibility and Artifact Consistency of the SIGIR 2022 Recommender Systems Papers Based on Message Passing. *arXiv*, 2025. Preprint, arXiv:2503.07823. Disponível em: <https://arxiv.org/abs/2503.07823>. Acesso em: 2 out. 2026.
- GOOGLE. Collaborative filtering. *Machine Learning: Recommendation Systems*. [S. l.], s.d. Disponível em: <https://developers.google.com/machine-learning/recommendation/collaborative/basics>. Acesso em: 2 out. 2026.
- KANG, Wang-Cheng; MCAULEY, Julian. Self-attentive sequential recommendation. In: *IEEE INTERNATIONAL CONFERENCE ON DATA MINING*, 2018. Proceedings [...]. IEEE, 2018. p. 197-206. Disponível em: <https://cseweb.ucsd.edu/~jmcauley/pdfs/icdm18.pdf>. Acesso em: 2 out. 2026.
- KLIMASHEVSKAIA, Anastasiia; JANNACH, Dietmar; ELAHI, Mehdi; TRATTNER, Christoph. A survey on popularity bias in recommender systems. *User Modeling and User-Adapted Interaction*, v. 34, p. 1777-1834, 2024. DOI: 10.1007/s11257-024-09406-0. Disponível em: <https://link.springer.com/article/10.1007/s11257-024-09406-0>. Acesso em: 2 out. 2026.
- MCAULEY, Julian. Recommender Systems and Personalization Datasets: Steam Video Game and Bundle Data. San Diego: University of California San Diego, s.d. Disponível em: https://cseweb.ucsd.edu/~jmcauley/datasets.html#steam_data. Acesso em: 2 out. 2026.
- NAÇÕES UNIDAS BRASIL. Objetivo de Desenvolvimento Sustentável 9: indústria, inovação e infraestrutura. [S. l.], s.d.a. Disponível em: <https://brasil.un.org/pt-br/sdgs/9>. Acesso em: 2 out. 2026.
- NAÇÕES UNIDAS BRASIL. Objetivo de Desenvolvimento Sustentável 12: consumo e produção responsáveis. [S. l.], s.d.b. Disponível em: <https://brasil.un.org/pt-br/sdgs/12>. Acesso em: 2 out. 2026.
- PATHAK, Apurva; GUPTA, Kshitiz; MCAULEY, Julian. Generating and personalizing bundle recommendations on Steam. In: *INTERNATIONAL ACM SIGIR CONFERENCE ON RESEARCH AND DEVELOPMENT IN INFORMATION RETRIEVAL*, 40., 2017. Proceedings [...]. ACM, 2017. DOI: 10.1145/3077136.3080724. Disponível em: <https://cseweb.ucsd.edu/~jmcauley/pdfs/sigir17.pdf>. Acesso em: 2 out. 2026.
- RENDLE, Steffen; FREUDENTHALER, Christoph; GANTNER, Zeno; SCHMIDT-THIEME, Lars. BPR: Bayesian personalized ranking from implicit feedback. In: *CONFERENCE ON UNCERTAINTY IN ARTIFICIAL INTELLIGENCE*, 25., 2009. Proceedings [...]. 2009. p. 452-461. Versão disponibilizada no arXiv em 2012. Disponível em: <https://arxiv.org/abs/1205.2618>. Acesso em: 2 out. 2026.
- SARWAR, Badrul; KARYPIS, George; KONSTAN, Joseph; RIEDL, John. Item-based collaborative filtering recommendation algorithms. In: *INTERNATIONAL CONFERENCE ON WORLD WIDE WEB*, 10., 2001. Proceedings [...]. ACM, 2001. p. 285-295. DOI: 10.1145/371920.372071. Disponível em: <https://archives.iw3c2.org/www10/cdrom/papers/519/node10.html>. Acesso em: 2 out. 2026.

APÊNDICE A PROVA DE CONCEITO DA ETAPA 2

Este apêndice registra a execução preliminar solicitada na etapa 2. Os valores foram calculados em Python em 2 de outubro de 2026, a partir de dados públicos reais. Não há simulação de interações, treinamento fictício ou estimativas de desempenho apresentadas como medidas. Os procedimentos descritos correspondem ao código incluído no pacote técnico complementar.

A.1 Bibliotecas e preparação

Tabela A1 Ambiente computacional utilizado

Componente	Versão	Finalidade
Python	3.12.14	Execução e bibliotecas padrão
pandas	2.2.3	Leitura, auditoria, agrupamentos e exportação
NumPy	2.3.5	Matrizes, amostragem e métricas
SciPy	1.17.0	Representação CSR e persistência do modelo
Matplotlib	3.10.8	Visualizações exploratórias e de desempenho

O carregamento emprega `gzip` e `ast.literal_eval`, pois os arquivos originais contêm dicionários Python por linha, e não necessariamente JSON estrito. Não se usa `eval`. A estrutura aninhada de reviews é expandida para uma linha por avaliação. O identificador do usuário é convertido em um pseudônimo estável por SHA-256, truncado em 20 caracteres hexadecimais; essa medida reduz exposição direta, mas não comprova anonimização irreversível.

A auditoria verificou ausência de campos obrigatórios vazios e identificou pares usuário-jogo repetidos. Antes da deduplicação, confirmou-se que nenhum par repetido possuía rótulos `recommend` conflitantes. Manteve-se a primeira ocorrência de cada par, retirando 874 linhas redundantes. Das 58.431 avaliações únicas, 51.692 são positivas e 6.739 são negativas. Apenas as positivas formam a matriz de recomendação; as negativas continuam disponíveis no arquivo auditável.


Tabela A2 Rastreabilidade da preparação

Etapa	Contagem
Linhas de usuários no arquivo original	25.799
Linhas sem reviews	28
Reviews após expansão	59.305
Usuários distintos com reviews	25.458
Pares duplicados removidos	874
Pares com rótulos conflitantes	0
Reviews únicas	58.431
Positivas / negativas	51.692 / 6.739
Usuários / jogos com positivos	24.124 / 3.292

A.2 Análise exploratória

A distribuição dos históricos é curta: entre usuários com pelo menos uma avaliação positiva, a média é 2,1428 jogos, a mediana é 1 e o terceiro quartil é 3; o máximo observado é 10. Esses resultados descrevem reviews disponíveis, não a biblioteca integral de jogos de cada pessoa. Não se pode concluir que os usuários só jogaram essa quantidade de títulos.

Figura A1 Distribuição dos históricos positivos




Fonte: elaboração própria com Steam v1 (UCSD). Prova de conceito, 02/10/2026.

Fonte: elaboração própria a partir dos arquivos públicos da coleção Steam (UCSD), 2026.

Somente 2.633 usuários têm cinco ou mais positivos e compõem a população elegível para validação e teste. O critério permite reservar dois itens e ainda manter

pelo menos três no treinamento de cada usuário avaliado. Os usuários com históricos menores permanecem no treino e contribuem para a estimação das relações item-item. Assim, a avaliação se concentra em usuários relativamente mais ativos e não representa adequadamente o início de uso do sistema por novos usuários.

Figura A2 Frequência de avaliações positivas por jogo



Fonte: elaboração própria com Steam v1 (UCSD). Prova de conceito, 02/10/2026.

Fonte: elaboração própria a partir dos arquivos públicos da coleção Steam (UCSD), 2026.

Os dez jogos mais frequentes concentram 28,50% das avaliações positivas. O jogo de ID 440 é o mais frequente, com 3.571 avaliações positivas. A curva em escala logarítmica evidencia concentração em poucos itens e uma cauda de jogos pouco avaliados. Popularidade é definida aqui como frequência de avaliações positivas; não é uma contagem de vendas nem uma medida direta de qualidade.

A matriz de treino contém 46.426 interações, 24.124 usuários e 3.103 jogos. Sua esparsidade é de 99,9380%, calculada por $1 - \text{interações} / (\text{usuários} \times \text{jogos})$. Esse cenário explica a dificuldade de inferir relações robustas para itens raros. Não se excluíram jogos apenas por baixa frequência; eventual alvo de validação ou teste ausente do vocabulário do treino permanece no denominador e recebe acerto zero.

A.3 Treinamento e protocolo de avaliação

Após deduplicação, os pares positivos são ordenados por pseudônimo de usuário e ID textual do item. Com gerador NumPy e semente 42, sorteiam-se, sem reposição, um positivo de validação e outro de teste para cada usuário elegível. A ordem retornada pelo sorteio define o primeiro como validação e o segundo como

teste. Os demais positivos compõem o treino. Não há pares usuário-jogo compartilhados entre as três partições, condição verificada por asserções no código.

Tabela A3 Partições do experimento

Partição	Interações	Uso
Treino	46.426	Estimar vocabulário, popularidade e similaridades
Validação	2.633	Escolher os hiperparâmetros do ItemKNN
Teste	2.633	Comparar modelos após a seleção

A divisão é aleatória por usuário, sem preservação cronológica global ou individual. Portanto, os resultados medem recuperação retrospectiva de avaliações omitidas. Não são evidência de capacidade de prever a próxima compra, nem excluem a possibilidade de treino conter avaliações publicadas depois de um alvo de teste. O objetivo é uma primeira verificação funcional; a análise temporal ficará para uma etapa com datas adequadamente tratadas.

A.3.1 Ajuste das similaridades

Seja X a matriz binária de treino. Para os jogos i e j , $n(i)$ e $n(j)$ são suas quantidades de usuários no treino, e $c(i,j)$ é a quantidade de usuários compartilhados. A similaridade por cosseno e sua redução por suporte são definidas operacionalmente por:

$$\cos(i,j) = c(i,j) / \sqrt{n(i) n(j)}$$

$$\text{sim}(i,j) = \cos(i,j) \times c(i,j) / (c(i,j) + \lambda), \text{ quando } \lambda > 0.$$

Quando $\lambda = 0$, utiliza-se diretamente $\cos(i,j)$. A diagonal é fixada em zero.

Para cada item de origem, conservam-se somente os k vizinhos de maior similaridade. A pontuação de um candidato corresponde à soma das similaridades que ele recebe dos itens positivos conhecidos do usuário: $\text{score}(u,j) = \text{soma, sobre } i, \text{ de } X(u,i) \text{ sim}(i,j)$. Empates de pontuação são resolvidos por popularidade no treino e, em seguida, pelo ID numérico crescente. Quando não há sinal colaborativo para candidatos, essa regra funciona como fallback de popularidade.

Foram avaliadas nove combinações: $k \in \{20, 50, 100\}$ e $\lambda \in \{0, 10, 50\}$. O critério de escolha foi o maior NDCG@10 médio na validação; em empate, seriam preferidos o menor k e o menor λ . O modelo selecionado utiliza $k = 100$ e $\lambda = 50$. Não se retreinou com validação antes do teste, de modo que ambos os modelos comparados usam exatamente o mesmo conjunto de treino. A popularidade é estimada pela soma das interações por item.

Tabela A4 Comparação de hiperparâmetros na validação

k	λ	NDCG@10
100	50	0,119683
50	50	0,118499
20	50	0,117763
100	10	0,117679
50	10	0,117290
20	10	0,114763
100	0	0,052010
50	0	0,040177
20	0	0,029922

Na implementação, X é esparsa, mas a matriz de coocorrência item-item é temporariamente densa. Com 3.103 itens, essa escolha é viável para a prova de conceito. Ela não demonstra escalabilidade para toda a coleção: a memória cresce quadraticamente com o número de itens. Para expansão, será necessário substituir esse passo por cálculo esparsa ou em blocos e medir custo computacional no ambiente de implantação.

A.3.2 Candidatos e medidas de avaliação

O catálogo candidato é formado pelos 3.103 jogos presentes no treino. Para cada usuário, excluem-se seus próprios positivos de treino e ordenam-se todos os candidatos restantes, sem amostragem de negativos. O positivo de validação não é excluído ao avaliar teste, pois o modelo não recebeu essa interação no treinamento. Os 103 alvos de teste ausentes do treino não podem ser recomendados e são contabilizados como falhas. Na validação, esse total é 94.

As métricas são médias por usuário. Com um único alvo relevante, seja r a posição desse alvo na lista e $h = 1$ se ele aparece entre os dez primeiros, ou 0 caso contrário. Então $\text{Precision@10} = h/10$; $\text{Recall@10} = h$; $\text{NDCG@10} = 1/\log_2(r + 1)$, quando $h = 1$, e 0 nos demais casos; $\text{MRR@10} = 1/r$, quando $h = 1$, e 0 nos demais casos. O DCG ideal é 1 nessa configuração. A precisão máxima observável é 0,1, não 1, porque apenas um item foi rotulado como relevante por usuário.


A cobertura é o número de jogos distintos expostos nas listas dividido por 3.103. A participação da cabeça é a fração de posições das listas ocupadas pelos 311 jogos mais populares do treino, correspondentes ao teto de 10% do catálogo. Esses cálculos utilizam todas as listas dos mesmos 2.633 usuários. Uma cobertura maior não demonstra, isoladamente, preferência pelos itens adicionais.

A.4 Resultados preliminares

Tabela A5 Desempenho dos modelos no teste

Medida	Popularidade	ItemKNN
Precision@10	0,022066	0,021003
Recall@10	0,220661	0,210027
NDCG@10	0,124555	0,119434
MRR@10	0,095050	0,091605
Cobertura do catálogo	0,48%	56,46%
Participação da cabeça	100,00%	85,07%

Figura A3 Acerto e cobertura dos modelos



Fonte: elaboração própria com Steam v1 (UCSD). Prova de conceito, 02/10/2026.

Fonte: elaboração própria a partir dos arquivos públicos da coleção Steam (UCSD), 2026.

A referência por popularidade obteve Recall@10 de 0,220661 e NDCG@10 de 0,124555. O ItemKNN obteve 0,210027 e 0,119434, respectivamente. A redução de NDCG@10 é de aproximadamente 4,11% em termos relativos. O resultado não sustenta a afirmação de que a personalização melhorou o acerto. Na própria validação, a popularidade já apresentava NDCG@10 maior (0,123613) que o melhor ItemKNN (0,119683); portanto, o modelo personalizado foi mantido no teste como comparação, não como vencedor antecipado.

Em contrapartida, a cobertura passou de 0,48% para 56,46%, correspondendo a 15 e 1.752 jogos distintos nas listas, respectivamente. A participação da cabeça caiu de 100% para 85,07%. A prova de conceito evidencia um compromisso: maior amplitude de exposição acompanhada de perda de recuperação dos alvos observados. Não se pode converter esse ganho de cobertura em uma conclusão sobre satisfação, justiça ou consumo responsável.

Como análise complementar, aplicou-se bootstrap pareado com 2.000 reamostragens de usuários e semente 42 à diferença de NDCG@10 entre ItemKNN e popularidade. A diferença média foi -0,005121, com intervalo percentil de 95% de [-0,009545; -0,000689]. O intervalo ficou abaixo de zero neste experimento. Essa análise é condicional a uma única divisão e a modelos fixos; não mede variabilidade entre sementes, não refaz a seleção de parâmetros e não representa todas as dependências induzidas por itens compartilhados. Não fundamenta uma conclusão universal de superioridade da popularidade.

A concentração dos dados, a mediana de apenas um positivo por usuário e a seleção de usuários mais ativos ajudam a interpretar os resultados, mas não estabelecem causalidade. São necessárias novas divisões, testes temporais e estudo do tratamento dos sinais negativos para distinguir a contribuição de cada fator. A decisão técnica desta etapa é conservar a popularidade como referência competitiva e tratar o ItemKNN como protótipo funcional que ainda exige aperfeiçoamento.

A.5 Demonstração e próximos passos

Para evitar escolher um exemplo apenas por ter dado certo, a demonstração utiliza o primeiro usuário da lista de teste ordenada pelo pseudônimo. Seu histórico de treino contém Garry's Mod, Train Simulator e Gone Home. A lista produzida é apresentada abaixo. Os títulos provêm dos metadados históricos e não atualizam automaticamente a nomenclatura comercial.

Tabela A6 Exemplo determinístico de recomendação

Posição	ID do jogo	Título
1	440	Team Fortress 2
2	730	Counter-Strike: Global Offensive
3	550	Left 4 Dead 2
4	304930	Unturned
5	252490	Rust
6	218620	PAYDAY 2
7	105600	Terraria
8	49520	Borderlands 2
9	265930	Goat Simulator
10	620	Portal 2

O alvo oculto desse usuário é The Interview (ID 348380), que não foi recuperado entre os dez primeiros. O exemplo confirma que o protótipo produz uma lista personalizada calculada a partir do treino, mas também mostra uma falha de recuperação. O escore colaborativo não é probabilidade de compra e a presença de títulos populares não garante sua pertinência para a pessoa.

A execução completa pode ser reproduzida com os scripts `preparar_dados.py` e `executar.py`. O pacote contém a base reduzida pseudonimizada, o dicionário de títulos, as partições, as métricas, os gráficos, a matriz de treino e o modelo ajustado. O arquivo `proveniencia.json` registra URLs e hashes dos arquivos originais; `resumo.json` registra versões, semente documentada no código e contagens. O uso da base reduzida permite repetir o experimento sem baixar novamente os textos das avaliações.

Para a etapa 3, propõe-se ampliar o desenho experimental com divisões independentes, bloqueio de itens explicitamente rejeitados, tratamento de usuários e jogos novos e comparação com uma técnica de fatores latentes. Uma avaliação temporal exige esclarecer datas incompletas ou adotar um arquivo com timestamps confiáveis. Qualquer escolha orientada pelos resultados atuais deverá ser reavaliada em novo teste reservado. O planejamento extensionista dependerá de público parceiro e de verificação direta de compreensão e utilidade, sem presumir benefício com base apenas em métricas offline.